# 基于多LLM协作的外语自然习得法教材生成框架

胡圣和 2026.3.30 hush@smail.nju.edu.cn

## 1. 原始问题概述

运用编写多模态教材所需的生成式模型及记录故事设定和发展所需的世界原型，动态创作包含很多episode的长horizon故事，同时达到三个目标：

1. **linguistic consistency:** 概念呈现顺序和语言水平变化符合自然习得规律
2. diversity: 情节、话题和模态呈现充分的多样性、趣味性
3. world consistency: 各模态语义对齐，故事以类似真人生活的方式演进

从而使得零基础学习者能循序渐进理解故事对话和情节、模仿NPC言行，高效提升综合外语能力，逐步达到高阶水平（C1/C2）。

该问题适合采用多LLM协作来解决。长期语言发展建模、跨模态严格对齐、情节逻辑连贯性以及多样性优化等子问题均涉及复杂约束，它们中的任何一个仅凭单LLM agent均难以驾驭。相较之下，多LLM系统可通过分层分工与迭代校验机制，协同满足上述目标。

## 2. 什么是自然习得法

一种建立在Krashen第二语言习得理论上的外语教学方法。模拟儿童下意识习得母语的自然过程，让零基础学习者沉浸在只含目标语言的环境中，持续接受可理解输入，循序渐进学会运用目标语言。

可理解输入主要有三类：

1. 蕴含直观语义的超语言信息。儿童在母语学习早期通过视、听、触等多种模态的输入来建立语言和具象事物的对应关系。它们同理可支持外语初学者建立初级语言概念。
2. 略高于现有水平的语言材料。它处于学习者语言能力的边界上，并指向该边界的扩展方向。例如，一个用学习者已知概念解释未知词汇的句子。
3. 同一语义的多样复现。从经验主义的角度，任何概念是由它的所有实例/具体表现定义的。学习者可以从蕴含同一语义的多种上下文归纳反复出现的事物、关系、规律，从而理解复杂语义。

基于可理解输入，自然习得法注重教学语义之间的相互关系及从具体到抽象、简单到复杂的语义结构，相对弱化显式的形式逻辑的灌输（例如中学英语课上的词性和语法讲解），而是期望学习者自然归纳规律。

原始问题要求实现的三个目标分别对应于外语习得环境的自然、全面和沉浸程度。

## 3. 问题MVP

整个系统的核心价值在于实现**linguistic consistency**。在此之上，辅之以基本的diversity（涵盖丰富的生活话题）和world consistency中的模态对齐（为实现超语言信息和语义复现提供重要保障），使得生成结果有趣并具有温和的理解梯度，让学习者有持续学习动力。world consistency中的长期逻辑连贯性不属于现阶段重点，暂不考虑。

## 4. 世界原型与故事的划分

世界原型$\mathcal{W}$规定了一组agents和模态，它们是呈现语言知识的主体和媒介。之所以不称为世界模型，是因为我们关心的只是$\mathcal{W}$能表达的故事，暂不要求具备一致动力学和交互功能的多模态系统。把生成多模态故事的模型笼统地记为$p_{\mathcal{W}}$。

- **agents**：若干个由系统操控的角色（NPC）。一般有一个ego NPC充当学生/儿童，模拟学习者对陌生外语的初始视角，具有受限、逐步发展的语言能力；另一些NPC充当导师/监护人，可能有常规语言能力，但其表达复杂度需以适合ego的水平为宜。
- 模态：$\mathcal{W}$至少能以标准的文本、视频、音频模态向用户呈现故事，这些模态构成完整状态$s=(s^p,s^t,s^v,s^a)$。其中$s^p$是世界本身的历史信息和物理状态，可能以基于谓词逻辑/自然语言的数据结构表达，其他模态都是用$p_{\mathcal{W}}$对其进行渲染的结果。进一步，可能引入口腔发声特征（口型、齿位、舌位）示意模态，使系统能提供更精细的语言指导。

此外，$\mathcal{W}$还包括记载故事的数据结构。现阶段采用text-based世界，即$s^p$以自然语言记录。

故事以**trajectory** $\tau=(\epsilon_1,\epsilon_2,\ldots)$ 形式呈现，由很多个**episode** $\epsilon_i$接续而成。每个episode是各NPC交互少量时间步的产物，其本质只是世界状态序列$s_{t_i:t_{i+1}}$。$\epsilon_i$对应于一组有独立语义和明确起止时间步的事件$\mathcal{E}_i=\{e_{i1},\ldots,e_{in_i}\}$，每个事件有描述文字，是对agent交互片段的事实陈述（例如，“mentor拿起苹果并递给student”）。这些事件由直接导致$\epsilon_i$各步状态转移的原子动作$a_{t_i:t_{i+1}}$实现。为简单起见，假设事件不交叠，即$\epsilon_i=(e_{i1},\ldots,e_{in_i})$。$\epsilon_i$对应于一个概念$\kappa_i$（形式可为单词、词组、短语乃至更复杂的语言结构），表明$\epsilon_i$是$\kappa_i$的实例、存在的目的是展示$\kappa_i$。

## 5. 问题的抽象形式

$$
\begin{aligned}
\max_{\pi} \quad & \mathbb{E}_{\tau\sim\pi,p_{\mathcal{W}}}[\mathrm{Div}(\tau)] \\
\text{s.t.} \quad & \mathrm{LingCons}(\tau)=1 \\
& \mathrm{ModalCons}(\tau)=1 \\
& \mathrm{SettingsCons}(\tau)=1
\end{aligned}
$$

- $\mathrm{Div}$：衡量情节/话题/模态整体多样性的某种指标
- $\mathrm{LingCons}$：保证ego agent的语言能力 / agents之间对话复杂度的发展符合自然习得规律
- $\mathrm{ModalCons}$：约束模态一致性，即事件的文本描述与实现它的原子动作及相应时间步上的$s^v,s^a$等模态有一致语义
- $\mathrm{SettingsCons}$：使连续的多个episodes的自然语言内容（场景和人物设定、情节发展顺序、人物对话）之间一致或连贯

# 6. 问题落实

自然习得法在现有文献中少有系统的形式化方案，多只关注某一指标的刻画而非长期习得规律的建模。因此LingCons的形式化是本研究的核心任务之一。

## 6.1 ModalCons

目前agents与$\mathcal{W}$的交互方式是先生成文本故事，再以其为prompt产生相应的音视频。因此，可截取各事件/episode的文本与相应的音视频区间，用CLIP/LanguageBind等多模态大模型嵌入到同一空间计算相似度：$\mathrm{sim}(\mathrm{emb}(s^i), \mathrm{emb}(s^j))) > \eta_{ij} \mid i, j \in \{t, v, a\}$。从实现角度，可参考[1][2]，采用专门的分步生成+迭代校验的多LLM工作流以及音视频对齐架构，以满足严格的细节/逻辑对齐要求。

## 6.2 SettingsCons

作为最次要的约束，不必专门形式化，只需在prompt中嵌入人设、关系、前若干episode的事件摘要，并推理当前episode的初始状态，即可保持情节基本一致。

## 6.3 LingCons

核心思路：**构建服从自然习得规律，同时与外界有自然的I/O接口的心智（概念）模型。**设计课程的LLM系统必须服从此模型的指导，进而实现约束。

LingCons包含三个相互关联的方面：

### 概念的扩展顺序

实现可理解输入，首先要保证episode展示的概念顺序得当，使得前序概念能支持后序概念的理解。这对只能由已有概念组合/难落实到多模态对象的抽象概念尤其必要。
借鉴计算机辅助教学中的知识图谱，引入概念依赖图$G_\kappa$，实现概念的有序扩展。$G_\kappa$借助LLM及专家知识，用更新规则来模拟人类概念边界扩展的过程，输入课程设计系统提议的新概念，并反馈时机成熟、适合教学的正式概念候选，动态保证当前episode的教学概念$\kappa_i$属于可理解输入：

$$\forall i, \mathrm{Support}(G_\kappa^{i-1}, \tau_{<i}, \kappa_i) = 1$$

$G_\kappa$的更新规则如下：

- **初始化**：人为确定最开始若干episodes的设定、情节及其表达的一组概念$\{\kappa_i\}_{i=1}^{I_0}$作为“种子”。这组概念基础得只需要多模态示例便可阐释。例如，“学生” “孩子” “老师” “父母” “苹果” “抓” “给” “移动”等等。
- **前驱维护**：为保持$G_\kappa$的轻量，限制每个概念的前驱$\leq K$个。可用哈希表/图管理系统维护$G_\kappa$中已有的概念，以便新的概念高效检索有关概念作为其候选前驱。
- **前驱检索**：图管理系统以$G_\kappa$为范围、LLM agent或单词知识图谱以自身知识为先验，均可为新概念提供候选前驱。可用另外一个LLM as judge综合这些信息，根据规则prompt选出最

合理的一部分作为前驱。例如，要求前驱必须是新概念的下列四种关系之一： 1. 最近的下位词 2. 较远的上位词 3. 同级词 4. 组成部分，分别对应于概念的归纳、演绎、类比和复合。

- **概念准入**：设$0 < K_0 < K$。当新概念$C$前驱数$k \geq K_0$时，将其加入$G_\kappa$中。但此时它还不是一个正式概念，而是近期有可能升格为正式概念的待定概念。只维护$\leq L$个前驱最多的待定概念。
- **多模态印象**：每当一个新episode及对应的正式概念产生，采用类似$\mathrm{ModalCons}$的方式计算前驱最多的$L_0 < L$个待定概念与此episode的模态一致性，并更新待定概念的多模态印象评分$m$，体现多模态历史对形成此概念的支持度。
- **概念转正**：$k, m$综合最优的几个待定概念会被支持成为正式概念候选，作为接下来生成episode的参考。

关于$G_\kappa$的理论可行性讨论参见附录A.1。

## 语言水平的渐进提升

从统计的角度，还需对episode中出现所有文本的水平进行约束，使得各个概念不仅以合适顺序展示，且在与之水平匹配的温和的上下文中展示。
采用多种语句结构和词汇复杂度指标构造综合水平指标$\phi(\tau, i)$，约束其提升和波动幅度：

$$\begin{aligned}
&\forall i, \mathrm{slope}(\phi(\tau, \cdot), w(i)) \in I_i^{\mathrm{slope}} \\
&\forall i, \forall j \in w(i), |\phi(\tau, j) - \mathrm{MA}(\phi(\tau, \cdot), w(i))| \leq \Delta_i^{\mathrm{fluct}}
\end{aligned}$$

其中$\mathrm{slope}(\cdot, w)$和$\mathrm{MA}(\cdot, w)$分别表示以$w$为窗口计算的平均斜率和滑动均值。$I_i^{\mathrm{slope}}$是允许的斜率区间。具体指标参见附录A.2。

## 语义复现和水平波动

语言习得是长期、重复的过程，概念仅在一个episode中出现是不够的。此外，引入小幅度的水平波动有利于知识泛化和长期保持。
将概念重复次数引入$G_\kappa$的扩展顺序规则，保证薄弱概念得以及时巩固。优化$\phi(\tau, i)$与概念平均层级$l(i)$的综合指标$\psi(\tau, i)$的多样性，促进知识泛化：

$$\forall i, H(\psi(\tau, \cdot), w(i)) \geq \eta_i$$

具体方案参见附录A.3。

上述约束总结为：

$$\mathrm{LingCons}(\tau) = 1 \iff \forall i, \begin{cases} \mathrm{Support}(G_\kappa^{i-1}, \tau_{<i}, \kappa_i) = 1 \\ \mathrm{slope}(\phi(\tau, \cdot), w(i)) \in I_i^{\mathrm{slope}} \\ \forall j \in w(i), |\phi(\tau, j) - \mathrm{MA}(\phi(\tau, \cdot), w(i))| \leq \Delta_i^{\mathrm{fluct}} \\ H(\psi(\tau, \cdot), w(i)) \geq \eta_i \end{cases}$$

## 6.4 Div

$$\mathrm{Div} = w_1 \mathrm{TopicDiv}(\tau) + w_2 \mathrm{EventDiv}(\tau) + w_3 \mathrm{ModalDiv}(\tau)$$

- $\mathrm{TopicDiv}$：基于预定义的话题细分类，用sentence transformer / LLM对每个episode的情节、概念分别打$C$个分类标签，计算分类变量的熵[3][4]。
- $\mathrm{EventDiv}$：对事件打上动作/发言/环境变化/心理描写等分类标签并计算熵。此外，可小权重奖励打破常规逻辑的事件，适度增加随机性[5]。
- $\mathrm{ModalDiv}$：统计正式/待定概念在$\tau$中与episode各模态相符的程度或频率分布。可在$G_\kappa$计算多模态印象时同步完成。
  $\kappa(\epsilon_i)$：在$\epsilon_i$中有多模态印象的正式/待定概念集。$m(\kappa, \epsilon_i)$：$\kappa$在$\epsilon_i$中的多模态印象总分。

$$\mathrm{ModalDiv}(\tau) = \frac{1}{|\tau|} \sum_{\epsilon_i \in \tau} \frac{1}{|\kappa(\epsilon_i)|} \sum_{\kappa \in \kappa(\epsilon_i)} m(\kappa, \epsilon_i)$$

$\mathrm{Div}$的三个分量指标均方便增量式更新。为不干扰前期单线学习初级概念，可动态调整$\mathrm{Div}$优化力度，适时形成支线。

# 7. 多LLM框架

现有用于结构化文本生成的多LLM系统，多采用分层文本规划和编排方法，这也适用于本问题。本方法分三层生成一个episode：

1. 规划高层情节
2. 生成故事文本
3. 生成其他模态

系统结构如下：

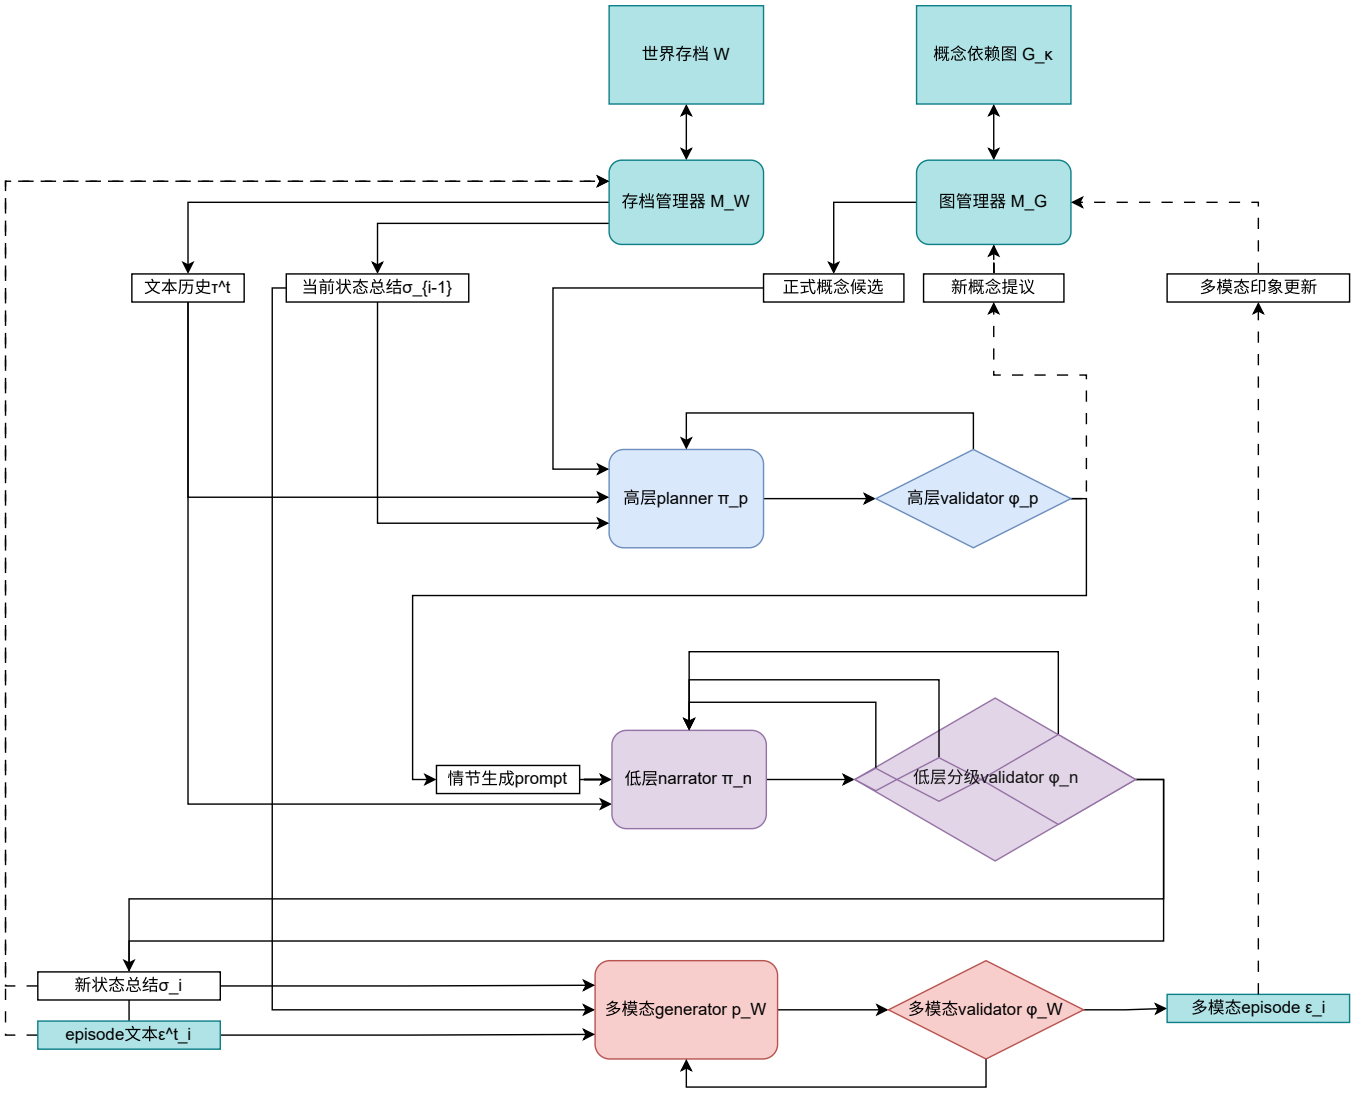


## 7.1 数据管理器

- 图管理器$M_G$：按前述规则维护$G_\kappa$，配有概念依赖关系生成/检验模块（单词知识图谱/单词提议LLM及LLM as judge），并提供高效检索$G_\kappa$的接口。
- 存档管理器$M_\mathcal{W}$：负责存储先前所有episode的文本历史$\tau^t_{<i}$，并能基于新的故事内容增量式更新完成$\tau_{\leq i}$时的状态$\sigma_i$。一般用一个RAG系统/LLM agent足够实现存取。可用另一个LLM agent对新episode进行情节一致性校验。

## 7.2 高层规划和校验

涉及的优化对象：$\mathrm{TopicDiv}, \mathrm{ModalDiv}, \mathrm{LingCons}, \mathrm{SettingsCons}$。

高层模块的任务主要有三方面：

- 维护和更新语言水平
  - 设定复杂度：按$\mathrm{LingCons}$定义的水平增长和波动曲线来更新当前episode $\epsilon_i$的预期语言水平$\phi(\tau, i)$、概念平均层级$l(i)$。
  - 提议新概念：利用$M_G$的概念依赖模块，推理待定概念/最高层正式概念的后继（与前驱生成反过来即可），并采样一部分，输入$G_\kappa$作为新概念。

    - 选择正式概念：从$G_\kappa$给出的正式概念候选中采样，转正并作为$\epsilon_i$对应的$\kappa_i$。偏好符合$l(i)$的概念。
    - 构思模态复现：从$G_\kappa$的待定概念中采样与$\kappa_i$相关且符合$l(i)$的一些概念，可在$\epsilon_i^t, \epsilon_i^v, \epsilon_i^a$等多模态中作为背景/次要物出现。迎合$\mathrm{ModalDiv}$。
- 促进$\mathrm{TopicDiv}$
  在提议新概念、选择正式概念时分别计算$G_\kappa$待定概念、$\tau$中已有概念$\{\kappa_j\}_{j<i}$的$\mathrm{TopicDiv}$，偏好能带来显著$\mathrm{TopicDiv}$增长的概念。这样可确保概念边界以各向均衡的方式扩展。
- 权衡连续性和多样性
  由于生活情节与概念关系往往有一致的局部性，概念扩展顺序与$\mathrm{SettingsCons}$容易同时满足。与此相反，$\mathrm{TopicDiv}, \mathrm{ModalDiv}$和语言水平波动鼓励多样性的同时容易造成逻辑上的跳跃，破坏连续的学习体验。
  为此，可以在若干episode构成的话题周期中维持低$\mathrm{TopicDiv}$权重和波动幅度，仅在周期结束时短暂调高。$\mathrm{ModalDiv}$也必须让位于主概念$\kappa_i$的呈现。

$\pi_p$根据上述要求选择正式概念、复现概念，构思episode大纲，高层validator $\phi_p$依次校验：

- 大纲能否正确呈现$\kappa_i$？
- 大纲能否以不超过$\phi(\tau, i)$的语言水平落实？若否，需进行删减。
- 大纲是否与话题周期一致？即，在周期内符合常规生活叙事，在周期末提供合理的逻辑跳跃？
- 复现概念是否复杂度合适、利于多模态呈现，且与$\kappa_i$主次分明？
  若否，适当砍掉一些概念，或选择$G_\kappa$/单词知识图谱中层级更低的概念。

$\phi_p$只对$\pi_p$的单次输出结果把关，无记忆；$\pi_p$根据$\phi_p$的多次反馈，用CoT逐步推理符合要求的情节生成prompt。最终构成：正式概念 + episode大纲 + 复现概念及呈现方式。

## 7.3 低层叙事和校验

涉及的优化对象：$\mathrm{EventDiv}, \mathrm{LingCons}, \mathrm{SettingsCons}$。

低层narrator $\pi_n$和validator $\phi_n$构成三级校验机制，落实严格的语言水平限制。
$\pi_n$接受情节生成prompt和前$k$个episode的故事文本$\tau^t_{-k:}$，以事件为单位进行故事续写。发言类事件中NPC的发言受到语言水平限制，其他事件的描述不限制用词范围。

1. word级校验：撰写发言内容时，确保NPC的用词范围严格受限。ego只能使用$G_\kappa$中的正式概念，mentor则可稍放宽，例如可用待定概念及接近$\kappa_i$难度的词汇。可在生成开始前计算合法词汇mask，并在发言内容开头以特殊标记token激活。借鉴lexically constrained decoding方向已有的GBS[6], FUDGE[7], PPLM[8]等工作，通过干预LLM的解码分布生成符合词汇约束的语句，同时保持较好的语义连续性。
2. event级校验：trajectory前期，由于词汇高度受限，发言内容难免存在表达不自然。但前期语言复杂度较低，因此可以并行生成多样候选，通过成对比较投票来保留最自然的发言。若

仍不达标，则需适度放宽限制再重新生成。

3. episode级校验：确保episode故事文本对$\kappa_i$的表达力以及服从$\mathrm{SettingsCons}$。类似event，多次采样并择优。

解码分布干预不仅适用于词汇范围限定，还可引导LLM生成的文本更精细地服从语言水平指标$\phi(\tau, i)$及词汇多样性。[9][10]

每完成一个event生成，可更新event分类计数，并调整下一event开头的event type / modal type 特殊标记token分布，以优化$\mathrm{EventDiv}$和$\mathrm{ModalDiv}$。

低层模块输出完整的episode文本$\epsilon_i^t$，不仅包含展示主概念$\kappa_i$的事件剧本，也嵌入了复现次要概念的其他模态描述。

### 7.4 多模态生成和校验

涉及的优化对象：$\mathrm{ModalCons}$。
从episode文本生成其余模态是一个独立的子问题，且已有基于多agent系统的闭环质量控制研究，此处不展开。[11][12]

## 8 展望

基于本工作可以对问题进行扩展：

1. 添加文本世界的长期叙事一致性和叙事特色（已有相关工作）
2. 引入用户接口，让用户操控ego，$G_\kappa$和$\tau$相应成为定制化的学情追踪模块和互动式教材
3. 将$\mathcal{W}/p_\mathcal{W}$升级为具有严格动力学的世界模型，尝试解决开放文本与封闭动力学的对齐挑战，提供更彻底的沉浸性（对标/超越现有的VR/AR语言学习产品）

## 9 研究价值 · 相关工作 · 新颖性

TODO

## 附录

### A.1 关于$G_\kappa$的理论可行性讨论

- **tractable**：通过限制图管理系统/LLM的query/prompt长度和结果长度，以及前驱/待定概念的数量不超过定值，能在近似常数复杂度内完成每episode一次的$G_\kappa$更新；$G_\kappa$的规模关于episode的数量也是近似线性的。
- **符合可理解输入原理**：$G_\kappa$建立的【正式-待定-未知】概念层次性体现了前两类可理解输入的交织。由于【具备相关概念 → 符合概念发展顺序 → 有多模态印象】三步筛选，**新概念（input）转化为被支持的概念（output）** 需要一定时间，体现外界新知渗入学习者有限的概念范畴的延迟。

- **是一种基础设施**：$G_\kappa$需要在外部新概念激励下才能实现概念的动态分层，可视为对ego NPC的心智建模，但它本身不具备形成特定新概念的倾向性。正如人的概念分布是在外界牵引下形成的，$G_\kappa$的发展也受具体学习材料的影响。
- **相对客观、严谨**：一方面，$G_\kappa$与$\tau$的上下文低耦合——更新过程中，$\tau$的具体上下文仅在被抽象为正式/待定概念后影响$G_\kappa$，仅体现概念分布的倾向，而不是作为一种prompt影响故事设定和发展逻辑。另一方面，LLM的作用是受限的——仅参与概念提取/筛选，受限于客观的图结构和规则，且概念的准入和转正最终由量化的数值来把关。因此，$G_\kappa$可视为对人的一般概念扩展规律的建模。求解形式化问题的过程，本质上是为了优化$\mathrm{Div}, \mathrm{SettingsCons}$等其他目标，让$G_\kappa$中的概念分布在满足此规律的同时产生特定偏向。

## A.2 语言水平指标$\phi$的选取

语言学研究已经提出了衡量语言水平的丰富的量化指标，例如：

- 句子结构复杂度指标
  - MLT：一段文本中T-unit的平均长度。T-unit指一个独立完整句子 + 它后面所有从属的小从句，MLT能直观反映每句话的信息量和组句能力。
  - CN/T：每个T-unit里的复杂名词短语数量，表征表达的丰富度是否靠近高阶。
- 词汇复杂度指标
  - TTR和MTLD：TTR=文本中不同词汇数量/词汇总数，反映词汇丰富度。由于TTR随文本长度增加而自然下降，MLTD（文本词汇多样性度量）对其进行修正，提供更稳定的对比标准。
  - AoA mean / max：词汇的习得年龄，用于度量词汇的高级感/成熟程度。若取最大值，可以实现硬性的难度分级约束。

已有工具可统计包含上述在内的多种指标[13]。综合指标$\phi(\tau, i)$可取这些指标的加权平均或组合。

## A.3 语义复现和水平波动的实现细节

实现重复：对$G_\kappa$中概念的扩展顺序约束进行推广，统计概念的重复次数（即与之对应的episode数）并添加鼓励重复的规则：设$R_0 > 0$，要求重复次数$\geq R_0$的概念才可作为前驱（基础牢固），且重复次数$< R_0$的正式概念有额外加分，近期会更频繁成为正式概念候选（趁热打铁）。统计可在$G_\kappa$计算多模态印象同时进行，不增加复杂度。

实现水平波动：

1. 维护体现概念和episode水平的指标$\psi(\tau, i)$，它由$\phi(\tau, i)$与表达概念在整个$G_\kappa$中的大致层级位置的“层级数”$l$构成。$l$可在计算前驱的同时增量式维护。例如，设$l \in [0, 1]$，种子概念的$l = 0$，初次计算前驱时新概念的$l$设为稍高于前驱$l$的平均，每当有概念转正，对所有概念的$l$进行归一化。
2. 计算窗口$w$内$\psi(\tau, i)$分布的多样性$H(\psi(\tau, \cdot), w(i))$可以用熵/到某目标分布的交叉熵等来表达。

可用认知科学理论来进一步细化、完善上述条件。例如，用艾宾浩斯遗忘曲线进行更准确的重复优先级建模。

## 参考文献

---


1. Beyond End-to-End Video Models: An LLM-Based Multi-Agent System for Educational Video Generation ↩
2. JavisDiT++: Unified Modeling and Optimization for Joint Audio-Video Generation ↩
3. StoryLensEdu: Personalized Learning Report Generation through Narrative-Driven Multi-Agent Systems ↩
4. Evaluating the Diversity and Quality of LLM Generated Content ↩
5. StoryBox: Collaborative Multi-Agent Simulation for Hybrid Bottom-Up Long-Form Story Generation Using Large Language Models ↩
6. Lexically Constrained Decoding for Sequence Generation Using Grid Beam Search ↩
7. FUDGE: Controlled Text Generation With Future Discriminators ↩
8. Plug and Play Language Models: A Simple Approach to Controlled Text Generation ↩
9. CEV-LM: Controlled Edit Vector Language Model for Shaping Natural Language Generations ↩
10. PPL-MCTS: Constrained Textual Generation Through Discriminator-Guided MCTS Decoding ↩
11. Enhance Multimodal Consistency and Coherence for Text-Image Plan Generation ↩
12. Multimodal diffusion framework for collaborative text image audio generation and applications ↩
13. Automatic analysis of syntactic complexity in second language writing | John Benjamins ↩